

Econometria I – Trabalho para casa

IE-UFRJ

Prof: Vitor Pereira

2025.02

1 Instruções

As questões 1 e 2 do trabalho deve ser entregues impreterivelmente até o dia 21 de novembro de 2025, às 23:59. A questão 3 deve ser entregue até o dia 05 de dezembro de 2025, no mesmo horário. Trabalhos entregues depois desses horários não serão corrigidos.

Este trabalho é para ser feito **em grupo**. O grupo deve ser formado por 3 alunos. É possível haver no máximo 1 grupo de 2 e um grupo de 4 na turma. O trabalho **NÃO** deve ser feito individualmente.

Vocês são livres para formar os grupos de 3 em até 1 semana. Caso nos grupos não estejam formados nesse prazo, procederei a um sorteio.

Infelizmente, nos últimos anos e especialmente após a pandemia, estamos perdendo o hábito de nos reunir e trabalhar presencialmente. Por isso, para que os trabalhos sejam admitidos, vocês deverão demonstrar com fotos, localização de gps ou outras provas **críveis**, que se reuniram pelo menos uma vez, de forma presencial para realizar o trabalho. Trabalhos feitos sem indícios suficientemente fortes de que foram feitos presencialmente e em grupo não serão aceitos.

Não usem IA a não ser para duvidas pontuais sobre programação. Quem vai se prejudicar são vocês, que irão aprender menos. Tudo bem utilizar IA para ajudar a escrever em Markdown ou Latex, mas não façam nada além disso. Há formas de se inferir se um texto ou um código foi produzido por IA. Se , de acordo com softwares de detecção de IA, alguma questão tiver mais de 80% de chances de ter sido gerada por IA, o trabalho inteiro será anulado.

2 R e RStudio

Antes de começar, vocês deverão instalar o R e o RStudio no computador. Seguem abaixo os links:

R: <https://cran.r-project.org/bin/windows/base/>

RStudio: <https://posit.co/download/rstudio-desktop/>

3 Linguagem

O trabalho deverá ser escrito em R Markdown (html) ou em Latex/Overleaf. Não aceitarei trabalhos escritos em word.

Para muitos de vocês, será a primeira vez que vocês irão escrever nessas linguagens. É normal que tenham alguma dificuldade no início, mas será recompensador começar a escrever em linguagens amplamente utilizadas em economia.

Todos os resultados e tabelas devem ser reportados com formatação adequada. Não postem print screens ou copiem e cole o output do R automaticamente.

4 Organização

Ao trabalharem com dados, é crucial que vocês tenham organização! Por isso:

1. Criem 5 pastas no diretório em que forem trabalhar
 - "code": Onde vocês irão escrever os códigos
 - "input": Onde ficam armazenadas as bases originais do projeto. É proibido salvar ou modificar qualquer arquivo dessa pasta
 - "tmp": Onde ficam os arquivos temporários, como modificações da base de dados original, ou qualquer outro arquivo (exceto códigos) que toma como input os dados armazenados na pasta "input" e transformam em "output". A lógica aqui é que qualquer arquivo dessa pasta possa ser deletado, sem prejuízo algum.

-
- "output": A pasta onde vocês irão salvar os resultados das estimações. Aqui vocês podem incluir a base de dados final, tabelas, gráficos, etc
 - "misc": Miscelanea. Aqui vai tudo não relacionado às 4 pastas anteriores.
2. Crie um RProject na pasta raiz, que contem as 5 pastas
 3. Crie um arquivo README.txt na pasta raiz, descrevendo o projeto
 4. Dentro da pasta "code", vocês devem ter um arquivo "_master". Crie um arquivo com esse nome. Dentro dele, deverão estar os caminhos para os diretórios onde vocês estarão trabalhando. Caso seja necessário reproduzir o código em outro computador, bastará apenas reescrever o caminho dos diretórios neste arquivo. Ao final do trabalho se encontra um exemplo de um arquivo "_master".
 5. Dê nome aos arquivos indicando a ordem em que eles devem ser rodados. Por exemplo: "1_abre_base", "2_limpa_dados", "3_regressoes", etc... Os nomes devem já ser sugestivos do que está sendo feito dentro de cada código.
 6. Preâmbulo. Inicie cada código indicando, com um comentário, qual é o objetivo do código (por exemplo: "Trabalho de econometria 1, prof Vitor Pereira, grupo XPTO, Objetivo: Limpar a base de dados, Data: Outubro de 2025,"etc).
 7. Ainda no preâmbulo, indique quais bases de dados são utilizadas como input, e quais são os produtos finais do código.
 8. Separe os códigos por funções. Por exemplo, você deve ter um código só para limpar base, outro só para rodar regressões, um para fazer gráficos, etc.... Evite códigos muito grandes que fazem muitas coisas. Quebre seus códigos em muitos arquivos, com funções específicas.
 9. Se você for escrever alguma função que será utilizada repetidamente em outros códigos, salve essa função em um código separado. O nome do arquivo deverá ser o nome da função, precedido de um ponto. Exemplo: ".funcao_monta_tabelas.R"
 10. Se puder, faça tudo dentro de um projeto de GitHub, o que facilitará refazer os passos e acompanhar o que seus outros colegas estão fazendo, de forma colaborativa.

5 Questão 1

Para esta questão, criem um novo RScript, abram um copiem o código que está no classroom e salvem o RScript.

O seed do arquivo deverá ser o DRE mais baixo do grupo.

```
1
2 # =====
3 # EXERCÍCIO DE ECONOMETRIA: ANÁLISE DO MERCADO DE TRABALHO BRASILEIRO
4 # Equação de Mincer para Retornos à Educação
5 # =====
6
7 library(dplyr)
8 library(ggplot2)
9 library(stargazer)
10 library(lmtest)
11 library(sandwich)
12 library(car)
13
14 set.seed(1234) # Coloque a aqui o DRE mais baixo
15
16 # =====
17 # PARTE 1: GERAÇÃO DOS DADOS
18 # =====
19
20 # Tamanho da amostra
21 n <- 2000
22
23 # Gera variáveis demográficas
24 data <- data.frame(
25   # Educação: anos de estudo (4 a 18 anos, média â 9.5)
26   education = pmax(4, pmin(18, round(rnorm(n, mean = 9.5, sd = 3.5)))),
27
28   # Sexo: 1 = masculino, 0 = feminino (52% homens)
29   male = rbinom(n, 1, 0.52),
30
31   # Raça: 1 = branco, 0 = preto/pardo (45% brancos no Brasil)
32   white = rbinom(n, 1, 0.45),
33
34   # Experiência: anos de experiência no trabalho (0 a 45 anos)
35   experience = pmax(0, pmin(45, round(rnorm(n, mean = 15, sd = 10)))),
36 )
37
38 # Gera regiões (distribuição populacional aproximada do Brasil)
39 regions <- c("North", "Northeast", "Southeast", "South", "CenterWest")
40 region_probs <- c(0.09, 0.27, 0.42, 0.14, 0.08) # Distribuição
   populacional aproximada
41 data$region <- sample(regions, n, replace = TRUE, prob = region_probs)
42
```

```

43 # Cria variáveis dummies para regiões (Sudeste como referência)
44 data$north <- ifelse(data$region == "North", 1, 0)
45 data$northeast <- ifelse(data$region == "Northeast", 1, 0)
46 data$south <- ifelse(data$region == "South", 1, 0)
47 data$centerwest <- ifelse(data$region == "CenterWest", 1, 0)
48
49 # =====
50 # PARTE 2: GERAÇÃO DE SALÁRIOS - ERROS HOMOCEDÁSTICOS
51 # =====
52
53 # Parâmetros da equação de Mincer (baseado na literatura brasileira)
54 beta_0 <- 6.8          # Intercepto (log do salário base â R$900)
55 beta_edu <- 0.13       # Retorno à educação (13% por ano de estudo)
56 beta_male <- 0.25      # Prêmio masculino (25%)
57 beta_white <- 0.18     # Prêmio para brancos (18%)
58 beta_exp <- 0.035      # Retorno da experiência (3.5% ao ano)
59 beta_exp2 <- -0.0005   # Experiência ao quadrado (retornos decrescentes)
60
61 # Efeitos regionais (Sudeste como referência)
62 beta_north <- -0.15    # Penalidade Norte
63 beta_northeast <- -0.20 # Penalidade Nordeste (maior efeito)
64 beta_south <- 0.08     # Prêmio Sul
65 beta_centerwest <- 0.05 # Pequeno prêmio Centro-Oeste
66
67 # Gera salários logaritmizados com erros HOMOCEDÁSTICOS
68 data$log_wage_homo <- beta_0 +
69   beta_edu * data$education +
70   beta_male * data$male +
71   beta_white * data$white +
72   beta_exp * data$experience +
73   beta_exp2 * data$experience^2 +
74   beta_north * data$north +
75   beta_northeast * data$northeast +
76   beta_south * data$south +
77   beta_centerwest * data$centerwest +
78   rnorm(n, mean = 0, sd = 0.35) # Erros homocedásticos
79
80 # Converte para níveis (salários em Reais)
81 data$wage_homo <- exp(data$log_wage_homo)
82
83 # =====
84 # PARTE 3: GERAÇÃO DE SALÁRIOS - ERROS HETEROCEDÁSTICOS
85 # =====
86
87 # Variância dos erros heterocedásticos como função de educação e experi

```

```

      ência
88 # Trabalhadores mais educados e experientes têm maior variância
      salarial
89 error_variance <- 0.25 + 0.015 * data$education + 0.005 * data$
      experience
90
91 # Gera erros heterocedásticos
92 hetero_errors <- rnorm(n, mean = 0, sd = sqrt(error_variance))
93
94 # Gera salários logaritmizados com erros HETEROCEDÁSTICOS
95 data$log_wage_hetero <- beta_0 +
96   beta_edu * data$education +
97   beta_male * data$male +
98   beta_white * data$white +
99   beta_exp * data$experience +
100   beta_exp2 * data$experience^2 +
101   beta_north * data$north +
102   beta_northeast * data$northeast +
103   beta_south * data$south +
104   beta_centerwest * data$centerwest +
105   hetero_errors # Erros heterocedásticos
106
107 # Converte para níveis
108 data$wage_hetero <- exp(data$log_wage_hetero)

```

5.1 Perguntas

1.1) Utilizando o pacote stargazer, faça uma tabela de estatísticas descritivas da sua base de dados.

Observe a sintaxe do comando stargazer (não esqueça de instalar e carregar o pacote antes de rodá-lo). A tabela deverá conter a média, a mediana, o desvio padrão, o valor mínimo, o valor máximo, e o número de observações.

Observe que se você está escrevendo em markdown, a tabela deverá ser feita em html. Se for feito no overleaf, a tabela deve ser salva em .tex.

1.2) Utilizando o pacote ggplot2, faça um scatterplot do salário (eixo y) contra educação em anos de estudo. Faça uma regressão linear utilizando o comando lm e plote os valores preditos no mesmo gráfico.

1.2) Faça o mesmo, agora com o log do salário.

1.3) Repita mais uma vez o exercício, plotando o log do salário (eixo y) contra a experiência

1.4) Utilizando o comando `lm`, rode uma regressão do log do salário em:

- Anos de estudo
- Experiência
- O quadrado da experiência
- Dummies regionais
- Dummy de sexo
- Dummy de raça

Caso seja necessário modificar ou criar alguma variável, utilize o pacote `dplyr`, e não `r-base`.

Note que as dummies já estão prontas para vocês, mas caso fosse necessário criá-las, vocês poderiam transformar as variáveis categóricas em "factors".

```
1 data$regiao <- relevel(factor(data$regiao), ref = "Sudeste")
```

1.5) Utilizando o pacote `stargazer`, reporte os resultados da regressão

1.6) Calcule os valores preditos e plote um gráfico 3d relacionando o log do salário, a experiência e os anos de estudo. Utilize o pacote `plotly`.

1.7) Calcule os resíduos da regressão e tire o quadrado dos resíduos. Plote um histograma dos resíduos.

1.8) Refaça os itens 1.4, 1.5, 1.6 e 1.7 utilizando a variável "log_wage_hetero". O que mudou no gráfico dos resíduos contra os anos de estudo?

1.9) faça um teste de White para testar a presença de heterocedasticidade na regressão do item 1.4 quando utiliza-se a variável `log_wage`.

1.10) Repita o teste de White quando rodamos a variável `log_wage_hetero`

```
1 library(lmtest)
2 m <- lm(y ~ x1 + x2, data = df)
3 bptest(m, ~ fitted(m) + I(fitted(m)^2))
```

Reporte o resultado (utilize o stargazer!)

1.11) Reestime a equação minceriana por FGLS. Reporte o resultado. As estimativas ficaram mais parecidas com o que deveríamos encontrar, de acordo com os parâmetros iniciais?

```
1 mincer_fgls <- lm(log_wage_hetero ~ x1+x2+x3+...Xk, data = data,
  weights = 1/sigma2_hat)
```

1.12) Rode novamente o código de geração dos dados, com uma amostra de 200 mil observações. Estime a equação minceriana para o log_wage_hetero por OLS e FGLS. Compare os resultados com os encontrados quando temos apenas 2 mil observações.

Repassé cambial

Considere o modelo de *série de tempo* (os dados estão em T2dados.xls) para calcular o repasse cambial para a inflação (escolha o setor que você preferir analisar). As variáveis são: **setorXX** – variação percentual mensal de preços dos setores da economia; **cambio** – variação percentual mensal da taxa de câmbio Reais por Dólar EUA fechamento compra; e **ibcbr** – variação percentual mensal da atividade do Banco Central do Brasil.

Rode a regressão:

$$\text{SetorXX}_t = \alpha + \beta_1 \text{cambio}_t + \beta_2 \text{ibcbr}_t.$$

[label=a)]

3. Interprete os coeficientes. Os sinais dos coeficientes estão corretos? Qual é o repasse cambial para os preços?
4. Teste a presença de autocorrelação utilizando o teste Ljung–Box. Quais as hipóteses nula e alternativa? Qual a sua conclusão para o teste?
5. Reestime o modelo incluindo dummies sazonais:

$$\text{SetorXX}_t = \alpha + \beta_1 \text{cambio}_t + \beta_2 \text{ibcbr}_t + \sum_j \delta_j \text{Sazonal}_j.$$

6. Interprete os coeficientes das dummies sazonais e compare a mudança nos demais coeficientes do item (c).

-
7. Teste a presença de autocorrelação utilizando o teste Ljung–Box. Qual a sua conclusão para o teste?
 8. Reestime o modelo incluindo a variável dependente defasada ($t-1$) e a variável câmbio defasada ($t-1$):

$$\text{SetorXX}_t = \alpha + \beta_1 \text{cambio}_t + \beta_2 \text{ibcbr}_t + \beta_3 \text{SetorXX}_{t-1} + \beta_4 \text{cambio}_{t-1} + \sum_j \delta_j \text{Sazonal}_j.$$

e responda qual é o **impacto total do repasse cambial** para os preços.

9. Teste a presença de autocorrelação utilizando o teste Ljung–Box e teste a presença de heterocedasticidade utilizando o teste Breusch–Pagan. Qual a sua conclusão para os testes?
10. Independentemente dos resultados dos testes no item (h), reestime o modelo usando o erro robusto a heterocedasticidade e autocorrelação (HAC). Com relação ao item (h), a significância dos parâmetros mudou?

6 Tamanho da turma e manipulação das notas na Itália

Nesta questão, iremos estimar o impacto do monitoramento da realização as provas dos alunos italianos (semelhante ao nosso SAEB/prova Brasil) sobre o desempenho escolar, com dados reais.

Nosso objetivo aqui é solucionar um puzzle. Nos dados dos exames dos alunos italianos (semelhante ao nosso SAEB/Prova Brasil). Quando exploramos a relação entre o número de alunos por turma e o desempenho dos estudantes, encontramos ganhos significativos de desempenho nas turmas menores. Isso é especialmente verdadeiro para o sul da Itália, sugerindo um retorno substancial da redução do tamanho das turmas para os residentes do Mezzogiorno.

Além de alto desemprego e outros problemas sociais, porém, o Mezzogiorno se distingue também por um outro problema: Através de um experimento aleatorizado, descobriu-se que existe uma manipulação generalizada das notas dos alunos. Quando fiscais, aleatoriamente distribuídos por escolas, estão presentes durante a realização das provas, as notas são diferentes de quando os fiscais não estão presentes.

Queremos testar, portanto, se o fato de turmas menores aumentarem as notas dos alunos no Mezzagiorno se deve à manipulação das notas, ou se realmente os alunos aprendem mais em turmas menores no Sul da Itália.

Dados Para estimarmos a relação entre o tamanho da turma e desempenho dos alunos no contexto italiano, iremos utilizar a base de dados `smallmo.dta` (Stata 11.2). O dicionário com o nome e significado das variáveis encontra-se no arquivo *dicionario_italia.xlsx*.

Antes de começar, crie um projeto e siga o passo a passo que descrevi no começo do trabalho. Isso irá facilitar muito a sua vida. Para isso, basta ir em "Files/new project". Depois crie um arquivo de R script novo e salve com algum nome nessa pasta.

Para importar a base em formato stata para o R, utilize o pacote `readstata13`

```
1 install.packages("readstata13")
2 library(readstata13)
3 Maimonides_italia <- read.dta13("smallmo.dta")
```

Antes de começar a escrever o código, você deverá instalar e abrir as bibliotecas dos pacotes que irá utilizar. Recomendo utilizar o pacote "pacman" que facilita essa parte.

3.1) Características da amostra e estatísticas descritivas

Primeiro, é importante conhecer melhor os dados que vocês têm em mãos. Através do pacote `stargazer`, faça uma tabela de estatísticas descritivas da sua base de dados.

Observe a sintaxe do comando `stargazer` (não esqueça de instalar e carregar o pacote antes de rodá-lo). Ela produz uma tabela com as características, e depois salva como um arquivo `html` ou `.tex`. O arquivo ficará disponível na pasta onde você criou o projeto.

3.2) Mostre as médias das seguintes variáveis, por região italiana e série:

- `answers_math_std`
- `answers_ital_std`
- `female`
- `immigrants_broad`
- `dad_lowedu`

-
- dad_midedu
 - mom_unemp
 - answers_math_pct
 - answers_ital_pct
 - our_CHEAT_ital
 - our_CHEAT_math

A variável de região é "area". O norte tem valor 1, o centro valor 2 e o sul valor 3. A variável de série é "grade".

Dica: Há várias formas de calcular essas médias. Uma delas é a partir do pacote dplyr, que é bastante poderoso e simples. Para manipular os dados usando o dplyr, olhe para a "folha de cola"(cheatsheet) na parte sobre "data manipulation with dplyr". Obviamente, não se esqueça de carregar o pacote e instalá-lo, caso não o possua instalado no computador. Logo há pouco mostrei como instalar e carregar o readstata13, o procedimento para o dplyr é o mesmo. Se utilizar o pacman, melhor ainda.

O dplyr funciona com "pipes", que são representados pelo símbolo de percentual, seguido pelo símbolo de maior > e de outro símbolo de percentual (% > %). O pipe simplesmente simboliza que os comandos são feitos em uma sequência. Por exemplo:

```
1 medias_cheap <- Maimonides_italia %>%
2   group_by(area, grade) %>%
3   summarise_at(c("our_CHEAT_ital", "our_CHEAT_math"), mean, na.rm =
   TRUE)
```

O que eu fiz aqui? Na primeira linha, apenas disse para o R: Crie uma base de dados chamada medias_cheap, essa base será feita a partir da base Maimonides_italia. Agrupe a base por área, depois tire as estatísticas descritivas das duas variáveis de fraude. O comando na.rm = TRUE diz ao R para não considerar nesse cálculo as observações com dados faltantes.

3.3) Aleatorização: Nesta parte do exercício, iremos calcular o impacto do monitoramento dos agentes do INVALSI (o teste de desempenho dos alunos italianos) sobre os indícios de manipulação e sobre a nota dos estudantes.

Primeiro, é importante checar se o experimento foi bem feito. Nesse caso, deveríamos ter um bom balanceamento das características dos alunos cujos professores foram monitorados e dos que não tiveram professores monitorados.

Por que é importante checar se existe esse balanceamento? Dê o exemplo de uma variável que, se estiver desbalanceada, poderia afetar nosso resultado? Explique em palavras por que ela poderia afetar o resultado.

3.4) **Balanceamento** Podemos fazer um teste t para algumas características como:

female immigrants_broad dad_lowedu dad_midedu mom_unemp

Isso pode ser feito através do comando `t.test(var1,var2)`.

Para isso, você pode criar uma variável `var1` como sendo a variável apenas para quem foi sorteado para ser monitorado e `var2` como sendo a mesma variável para quem não foi monitorado.

Dica: Você pode usar o comando "filter" do dplyr. Note que a variável do sorteio, ou nossa variável de "tratamento" é "o_math".

3.5) **Balanceamento através de regressão linear** Outra forma de fazer esse exercício é através de uma regressão linear. Nesta regressão, inclusive, podemos controlar pelo efeito de algumas variáveis, e calcular o erro padrão clusterizado.

Podemos fazer esse cálculo através do comando `lm` (linear model):

```
1 regressao1 = lm(mom_unemp ~ o_math, data=Maimonides_italia)
2 summary(regressao1)
```

Para incluir controles, basta colocá-los do lado direito da regressão no comando `lm`. Para incluir dummies ou efeitos fixos de uma variável como "region", basta incluir `factor(region)` no comando `lm`. Para incluir interações, use o símbolo `*`. Para calcular o erro padrão clusterizado, basta incluir `cluster="var"`. Exemplo:

```
1 regressao2 = lm(mom_unemp ~ o_math + factor(region) + factor(region)*+
  enrol_ins_snv, data=Maimonides_italia, cluster= "CLUSTER")
2 summary(regressao2)
3 stargazer(regressao1, regressao2, type= "html", out="balanceamento.html")
```

3.4) **Recortes** Use o comando "filter" para criar diferentes recortes da base. Refaça a tabela de balanceamento para o Norte, o centro e o Sul do país. Não se esqueça de

utilizar o stargazer.

3.5) Impacto do monitoramento: Para calcular o impacto do monitoramento, basta fazer o mesmo exercício, agora tendo como variáveis dependentes a porcentagem de testes com suspeitas de manipulação (em matemática e italiano) e a nota nos testes.

3.6) Monitoramento por regiões Utilizando apenas uma regressão linear, teste se há mais provas com suspeitas de manipulação nas regiões norte, centro ou no sul do país. Reporte através do Stargazer.

3.7) Notas por região Utilizando apenas uma regressão, teste se a nota dos testes na região sul muda mais com a manipulação do que na região norte.

3.8) Tamanho da classe Imagine que você queira testar se turmas menores melhoram o aprendizado dos alunos. Qual seria o problema de rodar uma regressão das notas no tamanho das turmas?

3.9) Maimônides Vamos agora aplicar o desenho de pesquisa quase-experimental introduzido por Angrist e Lavy (1999). Esse desenho explora variação no tamanho das turmas que decorre de regras que estipulam um limite (cutoff) para o tamanho da classe. Em Israel, com um limite de 40, espera-se ver uma única turma de 40 alunos em uma coorte de 40; já com matrícula de 41, a coorte é dividida em duas turmas bem menores.

Angrist e Lavy chamaram isso de “Regra de Maimônides”, em referência ao proeminente estudioso medieval Moisés Maimônides, que identificou regra semelhante no Talmud.

Vamos explorar os tamanhos mínimos e máximos de turma na Itália. Essas regras decorrem de uma regulamentação conhecida como Decreto Ministeriale 331/98. Até o ano letivo de 2008/09, as turmas do ensino primário estavam sujeitas a um tamanho mínimo de 10 alunos e a um teto de 25. Matrículas por série acima de 25, ou de um múltiplo desse valor, geralmente levavam à abertura de uma nova turma.

A regra, contudo, admite exceções. Diretores podem reduzir o tamanho de turmas frequentadas por um ou mais alunos com deficiência, e escolas em áreas montanhosas ou remotas podem abrir turmas com menos de 10 alunos. Por fim, a lei permite uma tolerância de 10% em relação ao máximo, para mais ou para menos. Isto é, o Ministério da Educação geralmente financia uma turma adicional quando a matrícula ultrapassa 22 e normalmente exige a abertura de uma nova turma quando a matrícula média, do contrário, excederia 28.

Uma reforma de 2009/10 elevou o máximo nominal para 27 e o mínimo para 15, novamente com tolerância de 10% (promulgada pelo Decreto del Presidente della Repubblica 81/2009). Essa reforma foi implementada gradualmente, um ano/série por vez, começando pelo 1º ano. Nos nossos dados, os alunos do 2º ano em 2009/10 e os do 5º ano em qualquer ano seguem a regra antiga, enquanto os alunos do 2º ano em 2010/11 e 2011/12 seguem a regra nova.

Questão: Por que é importante utilizar uma regra como essa para identificar o efeito? Como podemos explorá-la? Que hipóteses precisamos fazer para recuperar o efeito causal do tamanho da turma?

3.10) **RDD** Faça um scatterplot das notas dos alunos (por classe) e do tamanho predito da classe (`clsize_hat`). Estime uma regressão linear para o lado esquerdo do cutoff e do lado direito do cutoff. Plote no mesmo gráfico.

3.11) Faça o mesmo utilizando o tamanho predito da turma, em vez do valor real. Qual seria mais adequado para estimarmos a relação causal? Poderíamos ter um viés de variável omitida? Justifique

3.12) O fato de os professores ou diretores poderem alterar ligeiramente o tamanho das turmas pode invalidar a estratégia de descontinuidade de regressão? Por quê? Que outra técnica poderíamos combinar aqui? Por que? Faça uma DAG justificando sua resposta.

3.12) **Instrumentos:** Estime a relação entre tamanho da turma e desempenho através de variáveis instrumentais. Por que podemos utilizar o tamanho predito da turma como instrumento?

```
1 library(AER)
2 reg_maimonides <- ivreg(answers_math_std ~ clsize_snv | clsize_hat, data
  = Maimonides_italia, cluster="CLUSTER")
3 summary(reg_maimonides)
```

Não se esqueçam dos controles. E lembrem-se de que eles precisam entrar dos dois lados na sintaxe do `ivreg`.

3.13) **Interpretação:** Interprete o coeficiente. Como a manipulação dos testes pelos professores influencia o coeficiente? A manipulação deve ser maior ou menor para as classes maiores? Você acredita que o viés joga as estimativas que você acabou de calcular para cima ou para baixo?

3.14) Por último, vamos utilizar os dois instrumentos, em vez de somente um. Observe que temos duas variáveis endógenas, que são o tamanho da turma ("class size") e o índice de manipulação (our_CHEAT_ital ou our_CHEAT_math). Por outro lado, temos também dois candidatos à variável instrumental: A regra de maimônides e o sorteio para o monitoramento.

Você acredita que os candidatos à variável instrumental são razoáveis? Quais seriam as características ideais que eles deveriam satisfazer? Você crê que essas características estão satisfeitas?

3.15) **Identificação:** Esse modelo está sobre identificado, identificado ou não está identificado? Por quê?

3.16) Vamos calcular o impacto do tamanho da sala levando em conta o fato de que os professores podem estar manipulando as notas. Vamos instrumentar a porcentagem de testes suspeitos e o tamanho da sala pela regra de Maimônides e pelo sorteio do observador:

```
1 reg_maimonides2 <- ivreg(answers_math_std ~ clsize_snv + our_CHEAT_math |  
  clsize_hat + o_math, data = Maimonides_italia, cluster = "CLUSTER")  
2 summary(reg_maimonides2)  
3 stargazer(reg_maimonides, reg_maimonides2, type = "html", out = "iv.html")
```

Não se esqueça dos controles. Reporte os resultados.

3.17) **Interpretação:** O que aconteceu com o coeficiente do tamanho da sala? Compare com a estimativa que obtivemos quando apenas instrumentamos o tamanho da sala pela regra de Maimônides. Por que o resultado agora é diferente? O que isso nos revela sobre o efeito advindo da manipulação dos testes?